

MACHINE LEARNING AVANCÉ

21–25 SEPTEMBRE 2026
35 heures · M2 Data / IA

Chrys Fé–Marty NIONGOLO

RESSOURCES



ACCÈS PRIVÉ



Machine Learning Avancé · M2 Data / IA

CYBERSUP

2026 / 001

VOTRE FORMATEUR

**Chrys
Fé-Marty
NIONGOLO**

Machine Learning Avancé
Cybersup · Septembre 2026

UNE SEMAINE POUR PRATIQUER

Formateur : Chrys Fé-Marty NIONGOLO.

Une démarche centrée sur les mécanismes,
l'expérimentation et la justification des choix.

Des exemples calculables, des notebooks Python et un
projet à présenter en binôme.

[Profil LinkedIn de Chrys Fé-Marty NIONGOLO](#)



- 01 Évaluer et régulariser
- 02 Ensembles et optimisation
- 03 Déséquilibre et features
- 04 Clustering et anomalies
- 05 Interpréter et restituer

| APERÇU DU COURS

Évaluer, optimiser et interpréter des modèles.

Cours, TP Python et projet en binôme.



35 h en présentiel



5 journées

SOMMAIRE



Six compétences à démontrer

Compétence	Preuve attendue
Choisir un ensemble ou un clustering	Comparer des hypothèses et résultats
Optimiser sans contaminer le test	Pipeline et validation adaptée
Gérer classes rares et features	AP, calibration, seuil et ablations
Interpréter les prédictions	Diagnostic avec limites explicites
Évaluer de façon fiable	Protocole, variabilité et groupes
Préparer la reproductibilité	Environnement, manifeste et model card

SPE
DATA/IA

Exemple ou activité originale du cours



Prérequis et diagnostic

Python : fonctions, tableaux NumPy, DataFrame pandas et graphiques simples.

Statistiques : moyenne, variance, probabilité conditionnelle, corrélation.

ML : entraînement/test, régression, classification et lecture d'une matrice de confusion.

Diagnostic de 10 minutes puis groupes de travail complémentaires

Sources : R01, R33 · liens et détails dans les notes



Le rythme des cinq journées

SPE
DATA/IA

Jour	Thème	Pratique principale
Lun. 21/09	Évaluation, régularisation	TP00 + TP01
Mar. 22/09	Ensembles, optimisation	TP02 + TP03
Mer. 23/09	Classes rares, features	TP04
Jeu. 24/09	PCA, clustering, anomalies	TP05
Ven. 25/09	Explication, incertitude	TP06 + projet final

Chaque jour : 7 heures pédagogiques, pauses exclues

Exemple ou activité originale du cours



Le fil rouge : prioriser des appels

Décision : quels clients contacter avant une campagne ?

Prédiction : estimer une probabilité de souscription à partir des informations disponibles.

Évaluation : comparer au hasard, justifier le seuil et documenter les limites.

Un score de propension n'est pas l'effet causal d'un appel

Sources : R32, R39 · liens et détails dans les notes



Nos ressources de travail

Le diaporama pose les mécanismes et les questions à discuter.

Les notebooks contiennent des exemples, des exercices et des vérifications.

Le dépôt conserve le programme, les sources, le barème et les versions des dépendances.

CPU suffisant ; données des TP disponibles hors ligne après installation

Exemple ou activité originale du cours



Exécuter un exemple dans Colab

Importer un notebook autonome depuis le pack étudiant.

Installer les dépendances, puis exécuter les cellules dans l'ordre.

Sauvegarder le notebook et ses résultats avant de quitter la session.

SPE
DATA/IA

CPU pour les TP ; GPU facultatif pour la démonstration XGBoost

Sources : R43, R46 · liens et détails dans les notes



Ce que nous reprenons des supports de 2020

Le cadrage du problème, les types de variables et le cycle de projet.

Les arbres, la matrice de confusion et le raisonnement par scoring.

Une extension vers les ensembles, la validation robuste et l'incertitude.

SPE
DATA/IA

Exemples et illustrations du cours reconstruits et attribués

Sources : R38, R39 · liens et détails dans les notes



01 / Évaluer et régulariser

SPE
DATA/IA

Lundi 21 septembre · Construire une comparaison fiable



Le problème avant l'algorithme

Quelle décision sera prise, pour qui et à quel moment ?

Quelle cible observe-t-on, avec quel délai et quelles erreurs de mesure ?

Quelle population devra bénéficier du modèle une fois utilisé ?

Écrire la décision, l'horizon et la métrique avant d'entraîner

Sources : R38 · liens et détails dans les notes



Le contrat des données du fil rouge

SPE
DATA/IA

Élément	Choix pédagogique
Source	UCI Bank Marketing, CC BY 4.0
Fichier utilisé	bank-additional.csv : 4 119 lignes
Entrées	20 variables originales, 19 après exclusion
Cible	y = souscription oui / non
Variable exclue	duration, connue après l'appel
Limite	Historique 2008–2010, pas de date complète ici

Sources : R32 · liens et détails dans les notes



Trois familles de fuites

Fuite de cible : une variable encode directement ou indirectement le résultat.

Fuite de prétraitement : une moyenne, une sélection ou un encodage utilise le test.

Fuite de structure : le même client, document ou futur se retrouve des deux côtés.

Une variable disponible dans le fichier n'est pas forcément disponible à la décision

Sources : R02, R32 · liens et détails dans les notes



Entraînement, validation et test

Entraînement : ajuster les paramètres du modèle et les transformations.

Validation : choisir la famille, les hyperparamètres et le seuil.

Test final : estimer la performance d'une procédure désormais figée.

Regarder souvent le test revient à l'utiliser pour choisir

Sources : R03 · liens et détails dans les notes



Choisir le bon découpage

SPE
DATA/IA

Situation	Découpage	Risque si ignoré
Lignes indépendantes	Stratifié si classification	Proportion de classe instable
Plusieurs lignes par client	GroupKFold / split par client	Même personne des deux côtés
Prédire le futur	Blocs temporels + éventuel gap	Information future
Choisir des hyperparamètres	CV interne et externe	Score de sélection optimiste

Sources : R03 · liens et détails dans les notes



La pipeline apprend dans chaque pli

fit : apprendre l'imputation, les catégories, le scaling et le modèle sur le train du pli.

transform / predict : appliquer ces paramètres au pli de validation.

La sélection de variables et le sampling font aussi partie de cette procédure.

ColumnTransformer traite les colonnes ; Pipeline relie les étapes

Sources : R02, R18 · liens et détails dans les notes



La matrice de confusion se lit avec un coût

SPE
DATA/IA

Réel / prédit	Positif	Négatif
Positif	VP = 60	FN = 40
Négatif	FP = 90	VN = 810

1 000 observations : 60 vrais positifs et 90 faux positifs

Sources : R04, R39 · liens et détails dans les notes



Le piège de l'accuracy

Avec 99 % de négatifs, prédire toujours « négatif » donne 99 % d'accuracy.

Le rappel de la classe positive reste pourtant nul.


Comparer à DummyClassifier et rapporter les effectifs de chaque classe.

La métrique dépend de la décision, pas de ce qui donne le plus grand nombre

Sources : R04 · liens et détails dans les notes



ROC : ordonner les positifs et les négatifs



Chaque point correspond à un seuil.

Axe horizontal : FP / négatifs.


Axe vertical : VP / positifs.

Validation synthétique (n=420) ; les points de la courbe correspondent à différents seuils.

Sources : R04 · liens et détails dans les notes



Précision-rappel : regarder les alertes utiles



Précision : $VP / (VP + FP)$.

Rappel : $VP / (VP + FN)$.

La référence dépend de la prévalence.

Même validation que la ROC ; ligne de référence = prévalence observée. AP et aire trapézoïdale différent.

Sources : R04 · liens et détails dans les notes



Évaluer une régression

$$\text{MAE} = \text{moyenne } |y - \hat{y}| \quad \text{RMSE} = \sqrt{\text{moyenne } (y - \hat{y})^2}$$

MAE conserve une lecture en unités de la cible.

SPE
DATA/IA

RMSE pénalise davantage les grandes erreurs.

R^2 peut être négatif sur des données nouvelles.

Sources : R04 · liens et détails dans les notes



Minimiser une perte avec une pénalité

$$\theta^* = \operatorname{argmin}_{\theta} \left[(1/n) \sum l(y_i, f_{\theta}(x_i)) + \lambda \Omega(\theta) \right]$$

La perte mesure une erreur sur l'entraînement.

SPE
DATA/IA


La pénalité exprime une préférence pour certaines solutions.

La validation choisit la force de cette préférence.

Sources : R05 · liens et détails dans les notes



Biais et variance



Biais : erreur systématique liée à la famille de modèles.

Variance : sensibilité aux données d'entraînement.


Bruit : part irréductible du problème.

Courbes schématiques originales ; erreur = biais² + variance + bruit (0,5).

Sources : R08 · liens et détails dans les notes



Courbes d'apprentissage



Grand écart train/validation : examiner la variance.

Scores tous deux faibles : examiner biais, features et labels.


La courbe aide à juger l'intérêt de données supplémentaires.

Valeurs construites pour expliquer un diagnostic ; aucun résultat de benchmark.

Sources : R08 · liens et détails dans les notes



L1 et L2 n'ont pas le même effet



L2 réduit progressivement les coefficients.

L1 peut annuler certains coefficients.

Le scaling modifie le sens d'une pénalité sur les poids.

Exemple analytique à une variable, norme de x fixée et perte quadratique normalisée.

Sources : R05 · liens et détails dans les notes



Elastic Net et choix de régularisation

$$\Omega(w) = \alpha \|w\|_1 + (1 - \alpha) \|w\|_2^2 / 2$$

Le mélange associe parcimonie et stabilité de la pénalisation.

SPE
DATA/IA

Choisir l'intensité et le mélange dans la validation.

Dans LogisticRegression, un C plus petit renforce la régularisation.

Sources : R05 · liens et détails dans les notes



SVM : marge et noyaux

La marge sépare les classes en limitant certaines erreurs.

C règle le compromis entre violations de marge et régularisation.

Le noyau RBF introduit une portée locale contrôlée par gamma.

Standardiser puis régler C et gamma sur une échelle logarithmique

Sources : R06 · liens et détails dans les notes



TP01 : établir la baseline

Livrer une pipeline de prétraitement et une comparaison à DummyClassifier.

Comparer quatre valeurs de C avec les mêmes plis et la même métrique.

Rédiger les risques de fuite et les limites du découpage.

120 minutes · [notebooks/etudiants/01_evaluation.ipynb](#)

Sources : R02, R03 · liens et détails dans les notes



Quiz J1 : défendre son protocole

Peut-on standardiser tout le fichier avant une CV ?

Quel split choisir si un client possède dix lignes ?

Que signifie une AP supérieure avec un Brier moins bon ?

SPE
DATA/IA

Répondre seul, comparer en binôme, puis justifier

Sources : R02, R03, R16 · liens et détails dans les notes



Les acquis du jour 1

Une cible et un instant de décision explicites.

Une pipeline validée avec un découpage justifié.

Une baseline, des métriques adaptées et un test final préservé.



Demain : améliorer le modèle sans dégrader la qualité de la comparaison

Exemple ou activité originale du cours



02 / Ensembles et optimisation

SPE
DATA/IA

Mardi 22 septembre · Comparer performance, stabilité et coût



Un arbre partitionne l'espace

Une question sur une variable divise les observations en deux groupes.

Chaque feuille produit une valeur ou une distribution de classes.

Le choix local d'une division ne garantit pas le meilleur arbre global.

Une règle lisible peut appartenir à un arbre globalement instable

Sources : R40, R39 · liens et détails dans les notes



Calculer un gain de Gini

SPE
DATA/IA

Nœud	Positifs / total	Gini
Parent	4 / 10	0,48
Gauche	1 / 5	0,32
Droite	3 / 5	0,48
Après division pondérée	$0,5 \times 0,32 + 0,5 \times 0,48$	0,40
Gain	$0,48 - 0,40$	0,08

Sources : R40 · liens et détails dans les notes



Contrôler la complexité d'un arbre

`max_depth` limite la profondeur des interactions.

`min_samples_leaf` évite des feuilles soutenues par trop peu d'observations.

`ccp_alpha` pénalise la complexité lors de l'élagage.

SPE
DATA/IA

Les seuils se valident ; aucune taille minimale universelle de feuille

Sources : R40, R39 · liens et détails dans les notes



Bagging : moyenner des modèles instables

Tirer plusieurs échantillons avec remise à partir du train.

Ajuster un estimateur sur chaque échantillon bootstrap.


Agréger les prédictions pour réduire une partie de la variance.

Le bénéfice dépend autant de la diversité que du nombre d'estimateurs

Sources : R07, R08 · liens et détails dans les notes



Pourquoi la corrélation limite le gain



Erreurs identiques : ajouter des arbres apporte peu.

Erreurs diversifiées : la moyenne devient plus stable.

Une variance résiduelle reste lorsque p est positif.

Formule théorique avec variance égale et corrélation commune p .

Sources : R08 · liens et détails dans les notes



Random Forest : diversifier les divisions

Le bootstrap diversifie les lignes vues par chaque arbre.

max_features diversifie les variables candidates à chaque division.

n_estimators stabilise l'ensemble, au prix du calcul et du stockage.

SPE
DATA/IA

Comparer la force des arbres et la corrélation de leurs erreurs

Sources : R07 · liens et détails dans les notes



Out-of-bag : utile avec ses limites

Pour une observation, agréger les arbres qui ne l'ont pas utilisée.

Obtenir une estimation interne sans découpage de validation supplémentaire.

Vérifier que groupes, temps et prétraitements ne rendent pas l'estimation trompeuse.

OOB ne remplace pas un test cohérent avec l'usage futur

Sources : R07, R03 · liens et détails dans les notes



Boosting : corriger progressivement le modèle

$$F_m(x) = F_{m-1}(x) + \eta h_m(x)$$

F_{m-1} représente la prédiction courante.

h_m apprend une direction de correction.

η règle l'amplitude de chaque nouvelle correction.



Une itération de boosting à la main

Observation	y	F_0	Résidu	$F_1 (\eta=0,5)$
1	2	4	-2	3,25
2	3	4	-1	3,25
3	7	4	3	5,50

SPE
DATA/IA

La souche prédit -1,5 pour les deux premiers points et +3 pour le troisième

Sources : R11 · liens et détails dans les notes



Le gradient généralise le résidu

$\text{rim} = - \partial l(y_i, F(x_i)) / \partial F(x_i)$ à l'étape $m-1$

Ajuster un modèle faible sur cette direction de descente.

SPE
DATA/IA


Pour la log-loss, corriger une prédiction sur son échelle appropriée.

Répéter en contrôlant la capacité et la taille des mises à jour.

Sources : R11 · liens et détails dans les notes



Quand arrêter le boosting ?



Mesurer la RMSE sur une validation indépendante.

Réduire la complexité ou arrêter si la validation cesse de progresser.

Conserver un test indépendant de cette décision.

Expérience synthétique Friedman, $n=600$, graine 42 ; code dans scripts/build_assets.py.

Sources : R07, R09 · liens et détails dans les notes



Boosting par histogrammes

Regrouper les valeurs continues dans un nombre fini de bins.

Évaluer les divisions sur ces bins pour réduire le coût.

Régler feuilles, taux d'apprentissage, itérations et régularisation.

Un gain de calcul permet davantage d'expériences, pas un protocole moins strict

Sources : R07, R12 · liens et détails dans les notes



Quatre implémentations à connaître

Implémentation	Idée à retenir	Vigilance
HistGradientBoosting	Histogrammes intégrés à sklearn	Encoder/typer selon le pipeline
XGBoost	Objectif régularisé, second ordre	Paramètres et DMatrix
LightGBM	Croissance par feuille	Limiter feuilles et profondeur
CatBoost	Catégorielles et ordered boosting	Ne pas déléguer le split au modèle

SPE
DATA/IA

Sources : R11, R12, R13 · liens et détails dans les notes



Voting et stacking

Voting : combiner plusieurs prédictions selon une règle fixée.

Stacking : apprendre un méta-modèle sur les prédictions de modèles de base.

Pour le stacking, fabriquer ces prédictions sans avoir entraîné sur leur cible.

Prédictions hors pli pour le méta-modèle, test final pour l'ensemble

Sources : R07 · liens et détails dans les notes



TP02 : comparer les ensembles

Comparer Ridge, arbre, forêt et boosting sur les mêmes plis.

Tracer l'erreur du boosting au fil des itérations.

Justifier un compromis entre RMSE, coût et complexité.

70 min de TP + 20 min de démo · variantes locale et Colab

Sources : R07 · liens et détails dans les notes



Colab : XGBoost sur 41 188 lignes

Conserver l'ordre temporel : train, validation, puis test réservé.

Comparer une logistique et un boosting avec arrêt anticipé.

Mesurer qualité et temps, puis sauvegarder les preuves.

Démonstration de 20 minutes · CPU ou GPU NVIDIA facultatif

Sources : R32, R43, R46 · liens et détails dans les notes



Définir un espace d'hyperparamètres

Séparer les paramètres appris des réglages choisis avant fit.

Utiliser une échelle logarithmique pour C , λ ou le learning rate.

Limiter les plages grâce aux contraintes de temps et de mémoire.

Écrire le budget d'essais avant de lancer la recherche

Sources : R09 · liens et détails dans les notes



Grille, recherche aléatoire et TPE

La grille couvre une liste cartésienne de choix.

La recherche aléatoire explore une distribution de configurations.

TPE adapte les essais à l'historique de la recherche.

Le meilleur score interne est un résultat de sélection

Sources : R09, R10 · liens et détails dans les notes



Validation croisée imbriquée

Boucle interne : choisir les hyperparamètres sur le train externe.

Boucle externe : évaluer le choix sur un pli qu'il n'a pas vu.

Répéter pour estimer la performance de la procédure de sélection.

La boucle externe évalue une méthode de travail, pas un unique modèle final

Sources : R03, R09 · liens et détails dans les notes



L'optimisation a un coût mesurable

$$3 \times (8 \times 3 + 1) = 75 \text{ ajustements}$$

Trois plis externes, huit essais, trois plis internes.

SPE
DATA/IA

Un réajustement du gagnant dans chaque train externe.

Fixer le parallélisme pour ne pas saturer les machines.

Sources : R09 · liens et détails dans les notes



Interpréter une petite différence

Comparer les modèles sur les mêmes splits.

Examiner la dispersion, les segments et le coût d'usage.

Une différence de 0,003 AP n'est pas automatiquement utile ni robuste.

Les scores de plis corrélés ne sont pas des répétitions indépendantes

Sources : R03 · liens et détails dans les notes



TP03 : optimiser avec un budget fixé

Huit essais aléatoires et huit essais TPE par pli externe.

Même modèle, mêmes bornes et même métrique.

Restituer les scores externes et les limites de la comparaison.



90 minutes · [notebooks/etudiants/03_optimisation.ipynb](#)

Sources : R09, R10 · liens et détails dans les notes



Quiz J2 : mécanismes et protocole

Pourquoi 1 000 arbres identiques n'améliorent-ils pas une moyenne ?

Quel objet est appris à chaque étape du gradient boosting ?

Pourquoi le score du meilleur essai surestime-t-il sa performance future ?

Donner une justification avant de citer une bibliothèque

Sources : R08, R11, R09 · liens et détails dans les notes



Les acquis du jour 2

Diversifier pour stabiliser et corriger progressivement pour réduire l'erreur.

Régulariser les ensembles et surveiller le coût.

Évaluer la recherche elle-même avec une validation indépendante.

Demain : transformer une probabilité en décision dans un problème déséquilibré

Exemple ou activité originale du cours



03 / Déséquilibre et features

SPE
DATA/IA

Mercredi 23 septembre · Relier données, probabilités et décisions



Trois décisions différentes

Apprendre un score qui classe les observations.

Calibrer ce score pour estimer une probabilité.

Choisir une règle d'action selon les coûts et la capacité.

SPE
DATA/IA

Améliorer l'une de ces étapes n'améliore pas automatiquement les autres

Sources : R16, R17 · liens et détails dans les notes



Donner un coût aux erreurs

$$\text{Coût}(t) = \text{CFP} \times \text{FP}(t) + \text{CFN} \times \text{FN}(t)$$

Définir les coûts avec les personnes qui prennent la décision.

SPE
DATA/IA


Tester leur sensibilité plutôt que figer une valeur arbitraire.

Distinguer coût moyen, nombre d'alertes et contraintes de capacité.

Sources : R17 · liens et détails dans les notes



Le seuil doit être choisi sur validation



Un seuil bas augmente souvent rappel et volume d'alertes.

Le minimum de coût dépend des coûts choisis.

Le test final reste fermé pendant ce réglage.

Coûts pédagogiques sur validation synthétique. Le test ne sert pas à choisir le seuil.

Sources : R17 · liens et détails dans les notes



Un seuil théorique sous hypothèses

Agir si $p(y=1|x) > CFP / (CFP + CFN)$

Hypothèse : probabilités calibrées pour la population d'usage.

SPE
DATA/IA

Hypothèse : deux coûts fixes et aucun coût pour les décisions correctes.

Avec $CFP=1$ et $CFN=5$, le seuil théorique vaut $1/6$.

Sources : R17 · liens et détails dans les notes



$F\beta$ et rappel sous contrainte

$$F\beta = (1 + \beta^2) \times \text{précision} \times \text{rappel} / (\beta^2 \times \text{précision} + \text{rappel})$$

$\beta > 1$ donne plus de poids au rappel dans la moyenne harmonique.

SPE
DATA/IA

Un objectif « rappel maximal avec précision $\geq 60\%$ » est une autre règle.

Toujours rapporter les effectifs et la capacité nécessaire.

Sources : R04 · liens et détails dans les notes



Cinq leviers contre le déséquilibre

SPE
DATA/IA

Action	Ce qui change	Ce qui reste à évaluer
Poids de classes	Perte d'entraînement	Calibration et seuil
Sous-échantillonnage	Données majoritaires vues	Information perdue
Sur-échantillonnage	Fréquence des minoritaires	Surapprentissage
SMOTE / SMOTENC	Observations synthétiques	Géométrie, bruit, catégories
Réglage du seuil	Décision finale	Coût et capacité opérationnelle

Sources : R14, R17 · liens et détails dans les notes



Pondérer la fonction de perte

$$L = \sum_i w_i l(y_i, f(x_i))$$

Les observations coûteuses ou minoritaires contribuent davantage à l'objectif.

SPE
DATA/IA

`class_weight` ne crée aucune observation supplémentaire.

La probabilité produite peut nécessiter une recalibration.

Sources : R14, R16 · liens et détails dans les notes



SMOTE : interpoler dans la classe minoritaire

$$x_{\text{nouveau}} = x_i + u (x_{\text{voisin}} - x_i), \text{ avec } u \in [0,1]$$

Choisir un voisin minoritaire selon une distance.

Créer un point sur le segment qui relie deux observations.

Vérifier que cette interpolation reste plausible.



Sources : R15 · liens et détails dans les notes



Où placer le rééchantillonnage ?

Réserver le test avant tout sampling.

Dans chaque pli : apprendre le prétraitement et sampler uniquement le train.


Évaluer sur la distribution naturelle du pli de validation.

Utiliser `imblearn.Pipeline` pour encapsuler cette procédure

Sources : R14, R15 · liens et détails dans les notes



Lire une courbe de calibration



Une probabilité annoncée de 0,8 doit correspondre à environ 80 % de positifs.

La diagonale représente la calibration idéale.

Les bins rares rendent l'estimation incertaine.

Exemple schématique : une prédiction à 0,8 correspond ici à 0,64 observé.

Sources : R16 · liens et détails dans les notes



Apprendre une calibration sans fuite

Sigmoïde : transformation paramétrique relativement simple.

Isotone : transformation monotone plus flexible, exigeant assez de données.

SPE
DATA/IA

Les prédictions utilisées pour calibrer doivent venir de modèles qui n'ont pas vu ces labels.

CalibratedClassifierCV puis validation du seuil

Sources : R16 · liens et détails dans les notes



Concevoir des variables utiles

SPE
DATA/IA

Famille	Exemple	Contrôle
Valeurs manquantes	Imputation + indicateur	Appris sur train
Catégorielles	One-hot / target encoding	Inconnues et cross-fitting
Numériques	log1p, ratios, interactions	Domaine et unités
Temporelles	Retards, fenêtres passées	Aucune observation future
Sélection	L1, filtres, permutation	Ablation dans les plis

Sources : R18, R41 · liens et détails dans les notes



Valeurs manquantes et catégories inconnues

L'absence d'une valeur peut elle-même contenir un signal.

Distinguer « inconnu », « non applicable » et une vraie valeur nulle.

Prévoir les catégories inédites au moment de prédire.

L'imputation est une hypothèse, pas une restauration de la vérité

Sources : R18, R32 · liens et détails dans les notes



Target encoding et cross-fitting

$$\text{enc}(c) = (n_c \times \text{moyenne_c} + m \times \text{moyenne_globale}) / (n_c + m)$$

Résumer une catégorie avec une statistique de la cible et un lissage.

SPE
DATA/IA

Ne jamais calculer cette statistique à partir de sa propre cible sans contrôle.

Produire l'encodage d'entraînement par sous-plis adaptés au problème.

Sources : R19 · liens et détails dans les notes



Ratios, interactions et variables temporelles

Ratio : protéger le dénominateur et documenter les unités.

Interaction : exprimer une hypothèse entre deux facteurs.

Fenêtre : ne retenir que les événements antérieurs à la décision.

Une agrégation correcte dans le passé peut devenir une fuite si elle inclut le futur

Sources : R18, R32 · liens et détails dans les notes



Sélection de variables et ablation

Filtre : sélectionner selon une statistique avant le modèle, dans les plis.

Méthode embarquée : utiliser une pénalité ou le mécanisme du modèle.

Ablation : retirer un groupe de variables puis réévaluer la procédure.

La sélection supervisée fait partie de l'entraînement

Sources : R41, R25 · liens et détails dans les notes



Corrélation : deux précisions utiles

Pearson mesure une association linéaire, pas une causalité.

Un changement positif d'unité ne change pas Pearson.

Standardiser reste utile pour les distances, les pénalités et certaines optimisations.

Ne pas confondre covariance, corrélation et distance

Sources : R39, R18 · liens et détails dans les notes



TP04 : une décision validée

Comparer modèle simple, poids de classes et SMOTE sur train.

Calibrer, puis choisir le seuil sur validation avec les coûts fixés.

Ouvrir le test une fois et commenter les résultats, même décevants.

120 minutes · [notebooks/etudiants/04_desequilibre.ipynb](#)

Sources : R14, R16, R17 · liens et détails dans les notes



Atelier : auditer et enrichir les features

Examiner le dictionnaire UCI et l'instant de disponibilité de cinq variables.

Proposer deux transformations, dont une pour la sentinelle pdays=999.

Définir une ablation et le split permettant d'en mesurer l'intérêt.

60 minutes · docs/ATELIER_FEATURES.md

Sources : R19, R32 · liens et détails dans les notes



Quiz J3 : expliquer les compromis

Une probabilité bien calibrée impose-t-elle un seuil de 0,5 ?

Pourquoi ne pas équilibrer le test ?

Pourquoi une variable catégorielle presque unique est-elle risquée ?

Une réponse correcte doit préciser la population et le protocole

Sources : R14, R17, R19 · liens et détails dans les notes



Les acquis du jour 3

Des features disponibles à l'instant de décision et définies précisément.

Une stratégie de classes rares comparée sans fuite.

Une calibration et un seuil évalués dans le bon ordre.

SPE
DATA/IA

Demain : découvrir une structure quand la cible n'est pas donnée

Exemple ou activité originale du cours



04 / Clustering et anomalies

SPE
DATA/IA

Jeudi 24 septembre · Explorer une structure sans inventer une vérité



Un cluster dépend de la représentation

Choisir les variables définit ce qui peut rendre deux observations proches.

Choisir une distance définit la notion de ressemblance.

Choisir un algorithme ajoute des hypothèses sur la forme des groupes.

Un identifiant de cluster est un résultat d'algorithme, pas une classe naturelle

Sources : R20 · liens et détails dans les notes



Distances et échelles

Euclidienne : compare les écarts numériques coordonnée par coordonnée.

Cosinus : compare l'orientation de vecteurs, utile dans certains espaces textuels.

Des variables de grande amplitude peuvent dominer une distance brute.

Standardiser selon le sens métier, pas par automatisme

Sources : R18, R20 · liens et détails dans les notes



PCA : projeter en conservant de la variance

$$X_{\text{centré}} = U \Sigma V^T \quad Z_k = X_{\text{centré}} V_k$$

Les axes principaux sont orthogonaux.




Les premières composantes maximisent la variance projetée.

Réduire la dimension perd de l'information.

Sources : R22 · liens et détails dans les notes



Lire la variance expliquée



Deux axes expliquent ici 75 %.

Trois axes expliquent 88 %.

Quatre axes sont nécessaires pour dépasser 90 %.

Spectre construit pour l'exercice : les 3 premiers axes expliquent 88%, les 4 premiers 96%.

Sources : R22 · liens et détails dans les notes



K-means : minimiser l'inertie

$$J = \sum_k \sum_{i \in C_k} \|x_i - \mu_k\|^2$$

Affecter chaque point au centre le plus proche.

SPE
DATA/IA

Recalculer chaque centre comme la moyenne de son groupe.

Répéter jusqu'à convergence vers une solution locale.

Sources : R20 · liens et détails dans les notes



Une itération de K-means

SPE
DATA/IA


Points en 1D	Centre initial	Affectation	Nouveau centre
1, 2	0	Groupe A	1,5
8, 9	10	Groupe B	8,5
Inertie avant mise à jour	10	Somme des carrés	
Inertie après mise à jour	1	Somme des carrés	

Points 1, 2, 8, 9 : les deux moyennes sont 1,5 et 8,5

Sources : R20 · liens et détails dans les notes



Une géométrie que K-means représente mal



Les deux lunes sont des groupes courbes.

K-means favorise des régions proches de centres.


Une partition peut être stable et mal correspondre à la structure voulue.

Mêmes 180 lunes synthétiques, graine 42. Les couleurs représentent les clusters estimés.

Sources : R20 · liens et détails dans les notes



L'inertie ne choisit pas K à votre place



Ajouter des centres peut toujours réduire l'inertie optimale.

Le coude n'est pas toujours visible ni unique.

Croiser le diagnostic avec stabilité et utilité métier.

L'inertie optimale décroît avec K ; cette courbe ne prouve pas le vrai nombre de groupes.

Sources : R20 · liens et détails dans les notes



Silhouette : séparation et compacité

$$s(i) = [b(i) - a(i)] / \max(a(i), b(i))$$

$a(i)$: distance moyenne aux membres de son groupe.

$b(i)$: plus petite distance moyenne vers un autre groupe.

Une silhouette négative signale une affectation localement discutable.



GMM : une appartenance probabiliste

$$p(x) = \sum_k \pi_k N(x; \mu_k, \Sigma_k)$$

Une composante porte un poids, une moyenne et une covariance.



Les covariances autorisent des formes elliptiques.

Une observation peut avoir des responsabilités réparties entre composantes.

Sources : R21 · liens et détails dans les notes



EM : alterner deux problèmes plus simples

Étape E : estimer les responsabilités avec les paramètres courants.

Étape M : réestimer poids, moyennes et covariances avec ces responsabilités.

Répéter, puis comparer initialisations et complexités.

EM peut converger vers un optimum local

Sources : R21 · liens et détails dans les notes



Classification hiérarchique agglomérative

Partir de petits groupes puis fusionner progressivement.

Le linkage définit le coût ou la distance entre groupes.

La coupe du dendrogramme fixe la granularité retenue.

Ward s'appuie sur la variance et une géométrie euclidienne

Sources : R20 · liens et détails dans les notes



DBSCAN : relier les régions denses

eps définit le rayon du voisinage.

min_samples définit le soutien local requis pour un point cœur.


Les points non rattachés à une région dense peuvent être marqués bruit.

Densité et distance dépendent de l'échelle des variables

Sources : R20 · liens et détails dans les notes



Les mêmes lunes avec DBSCAN



La connexité locale suit ici les formes courbes.

Les points isolés peuvent rester sans groupe.

Changer eps peut fusionner ou fragmenter la partition.

Mêmes 180 lunes synthétiques, graine 42. Les couleurs représentent les clusters estimés.

Sources : R20 · liens et détails dans les notes



HDBSCAN : examiner plusieurs échelles

Construire une hiérarchie fondée sur la densité.

Extraire des groupes selon leur persistance dans cette hiérarchie.

Régler `min_cluster_size` et examiner le taux de bruit.

Vérifier la convention de `min_samples` selon l'implémentation

Sources : R23 · liens et détails dans les notes



Comparer les familles de clustering

SPE
DATA/IA

Méthode	Forme / hypothèse	Paramètre principal
K-means	Groupes compacts euclidiens	K
GMM	Mélange de gaussiennes	K + covariance
CAH Ward	Fusion selon variance	Coupe / nombre de groupes
DBSCAN	Connexité par densité	eps + min_samples
HDBSCAN	Densités à plusieurs échelles	min_cluster_size

Sources : R20, R21, R23 · liens et détails dans les notes



Évaluer sans labels

Tester la sensibilité aux graines, aux sous-échantillons et aux paramètres.

Décrire tailles, profils, bruit et cas atypiques de chaque groupe.

Faire valider une utilité concrète avec les personnes concernées.

Stabilité, séparation et utilité répondent à des questions différentes

Sources : R20 · liens et détails dans les notes



Projections : explorer avec prudence

PCA représente principalement de la variance linéaire.

t-SNE privilégie certaines relations de voisinage local.

Les paramètres peuvent modifier l'apparence des « îlots ».

SPE
DATA/IA

Un joli nuage 2D ne démontre pas le nombre de clusters

Sources : R22, R42 · liens et détails dans les notes



Anomalie, nouveauté et classe rare

Une anomalie est atypique selon une représentation et un modèle de référence.

Une classe rare peut être parfaitement normale.

La détection de nouveauté suppose un apprentissage représentatif du fonctionnement normal.

Un score d'anomalie doit être relié à une procédure de vérification

Sources : R24 · liens et détails dans les notes



TP05 : expliquer une partition

Comparer quatre méthodes sur les mêmes données et les mêmes échelles.

Rapporter silhouette, bruit, stabilité et ARI sur les données synthétiques.

Présenter un exemple de partition trompeuse et sa cause.

150 minutes · [notebooks/etudiants/05_clustering.ipynb](#)

Sources : R20, R21 · liens et détails dans les notes



Quiz J4 : reconnaître les hypothèses

Une baisse d'inertie prouve-t-elle que le nouveau K est meilleur ?

Une bonne silhouette suffit-elle si 70 % des points sont classés bruit ?

Une composante PCA est-elle forcément prédictive de la cible ?



Sources : R20, R22 · liens et détails dans les notes



Les acquis du jour 4

Une représentation et une distance explicites.

Des méthodes comparées selon leurs hypothèses géométriques.

Une partition évaluée par plusieurs diagnostics et un usage concret.

SPE
DATA/IA

Demain : expliquer, documenter et défendre le modèle final

Exemple ou activité originale du cours



05 / Interpréter et restituer

SPE
DATA/IA

Vendredi 25 septembre · Défendre une décision avec ses limites



Trois niveaux d'explication

Global : quelles variables le modèle utilise-t-il sur une population ?

Local : pourquoi produit-il cette prédiction pour cet exemple ?


Action : quelle intervention changerait réellement le résultat ?

Une explication prédictive ne répond pas automatiquement à une question causale

Sources : R25, R27 · liens et détails dans les notes



Importance par permutation



Mélanger une variable puis mesurer la dégradation du score.

Répéter pour observer la variabilité.

Interpréter sur un jeu de diagnostic réservé.

Friedman synthétique : x0 à x4 sont informatives par construction. Importance sur validation, 5 permutations.

Sources : R25 · liens et détails dans les notes



Variables corrélées : une explication ambiguë

Deux variables substituables peuvent se partager une information.

La permutation isolée peut sous-estimer leur rôle conjoint.

Permuter un groupe cohérent ou comparer une ablation groupée.

Une faible importance individuelle ne signifie pas « variable inutile »

Sources : R25, R27 · liens et détails dans les notes



PDP et ICE

PDP : moyenne des prédictions lorsque l'on fait varier une feature.

ICE : une courbe par observation pour montrer l'hétérogénéité.

Les combinaisons fabriquées peuvent être irréalistes avec des variables corrélées.

Lire l'échelle de sortie et l'espace dans lequel les observations sont plausibles

Sources : R26 · liens et détails dans les notes



SHAP : répartir une différence de prédiction

$$f(x) = \phi_0 + \sum_j \phi_j$$

ϕ_0 est une valeur de référence définie par l'explication.

ϕ_j répartit une contribution selon une règle de coopération.

La référence et les dépendances entre variables changent l'interprétation.



Un calcul de Shapley à deux variables

SPE
DATA/IA

Coalition S	$v(S)$	Calcul
Aucune variable	10	Valeur de référence
{A}	14	Contribution de A seule : 4
{B}	12	Contribution de B seule : 2
{A,B}	20	Interaction incluse
Attributions	$\phi A = 6 ; \phi B = 4$	$10 + 6 + 4 = 20$

$$\phi A = \frac{1}{2} [(14-10) + (20-12)] = 6 ; \phi B = 4$$

Sources : R27 · liens et détails dans les notes



Une prédiction ponctuelle laisse une incertitude

$\hat{y}$ donne un centre, sans dire à quel point l'erreur peut être grande.

Un intervalle vise une fréquence de couverture définie.

Sa largeur doit être interprétée avec cette couverture.

Un intervalle large peut être honnête mais peu utile pour décider

Sources : R29 · liens et détails dans les notes



Split-conformal : trois ensembles séparés

$$s_i = |y_i - f(x_i)| \quad q = s(k), k = \lceil (n_{\text{cal}}+1)(1-\alpha) \rceil$$

Entraîner f sans utiliser les données de calibration conforme.

Calculer les résidus absolus sur calibration et choisir le rang corrigé.


Produire $[f(x)-q, f(x)+q]$ pour une nouvelle observation.



Sources : R29 · liens et détails dans les notes



Lire les intervalles conformes



Certaines observations peuvent sortir de leur intervalle.

Une couverture de 90 % est une propriété marginale sous hypothèses.

Le test fini peut afficher une couverture différente de 90 %.

Split-conformal 90% : 600 train, 200 calibration, 200 test ; extrait des 40 plus petites prédictions. Couverture marginale, pas individuelle.

Sources : R29 · liens et détails dans les notes



Évaluer des segments

Rapporter performance et effectifs pour des groupes pertinents.

Examiner rappel, calibration et types d'erreurs.

Signaler les petits échantillons et les populations absentes.

Une moyenne satisfaisante peut masquer un échec local

Sources : R30, R16 · liens et détails dans les notes



Préparer un modèle à être utilisé

Sérialiser toute la pipeline avec son schéma d'entrée.

Enregistrer versions, données, paramètres, seuil et protocole.

Prévoir surveillance, responsable et procédure de retour arrière.

SPE
DATA/IA

Une bonne notebook n'est pas encore un service exploité

Sources : R31, R30 · liens et détails dans les notes



Trois dérives à distinguer


Signal	Observation	Action à instruire
Qualité des entrées	Manquants, catégories nouvelles	Vérifier collecte / schéma
Dérive de X	Distribution différente	Analyser origine et segments
Performance avec labels	AP, rappel, coût, calibration	Comparer à la référence
Dérive de $P(y X)$	Relation prédictive changée	Réévaluer / réentraîner
Incident	Dépassement d'un seuil convenu	Alerter et envisager retour arrière

SPE
DATA/IA

Sources : R30 · liens et détails dans les notes



Une distribution différente n'est qu'un signal



Les nouvelles entrées se déplacent vers les grandes valeurs.

Cela peut changer la fréquence des décisions.

Les labels restent nécessaires pour mesurer certaines pertes de qualité.

Distributions construites : un changement de $P(X)$ ne prouve pas une baisse de performance.

Sources : R30 · liens et détails dans les notes



La model card rend les limites visibles

Usage prévu, utilisateurs et cas exclus.

Données, protocole, métriques globales et par segment.

Hypothèses, limites, responsable et conditions de réévaluation.

Écrire ce que le modèle ne permet pas de conclure

Sources : R30, R32 · liens et détails dans les notes



TP06 : expliquer et quantifier

Mesurer une importance par permutation et discuter les corrélations.

Comparer PDP et ICE sur une relation synthétique connue.

Construire un intervalle conforme et vérifier sa couverture observée.

SPE
DATA/IA

90 minutes · [notebooks/etudiants/06_interpretation.ipynb](#)

Sources : R25, R26, R29 · liens et détails dans les notes



Veille au 19 septembre 2026

scikit-learn 1.9.1 : environnement utilisé pour les TP.

TabArena : comparer les méthodes avec leurs budgets et protocoles.

Modèles tabulaires de fondation : un axe de recherche à évaluer.

La nouveauté ne dispense pas d'une baseline ni d'un test adapté

Sources : R34, R36, R44, R45, R47, R48, R49 · liens et détails dans les notes



TabPFN : publication et annonce récente

2025 : article Nature sur TabPFN v2 et les petits jeux tabulaires.

15 septembre 2026 : rapport technique TabPFN-3.5 publié par Prior Labs.

Comparer qualité, coût, conditions d'accès et proximité avec nos données.

Une annonce de l'éditeur et une validation indépendante n'ont pas le même statut

Sources : R35, R37 · liens et détails dans les notes



Lire un benchmark de façon critique

Quels jeux, tailles, types de variables et risques de contamination ?

Quels budgets, hardware, tuning et ensembles par méthode ?

Quelles distributions de résultats et quels cas d'échec ?

Une moyenne ou un rang ne remplace pas une expérience sur notre problème

Sources : R36, R37 · liens et détails dans les notes



Projet final : prioriser une campagne

Reprendre les données UCI, la décision et les contraintes de disponibilité.

Comparer une baseline et deux familles avec un budget explicite.

Fixer modèle et seuil, évaluer le test puis défendre la recommandation.

180 minutes · binôme · notebook, manifeste, model card et restitution

Sources : R32, R30 · liens et détails dans les notes



Une évaluation sur des preuves

SPE
DATA/IA

Critère	Points / 20	Preuve
Protocole sans fuite	5	Splits, prétraitement, test figé
Comparaisons et optimisation	4	Baseline, budget, dispersion
Classes rares et décision	3	AP, calibration, seuil
Interprétation et limites	3	Explication critique et model card
Reproductibilité	3	Exécution, versions, manifeste
Restitution	2	Conclusion argumentée

Exemple ou activité originale du cours



Soutenance : cinq minutes pour décider

Quelle décision et quelle population avez-vous définies ?

Quelle preuve justifie votre choix de modèle et de seuil ?

Quelle limite vous empêche encore de recommander un usage réel ?

Répondre avec un résultat, son protocole et une limite concrète

Exemple ou activité originale du cours



Quiz final : raisonner sur un cas nouveau

Un score augmente après ajout d'une variable connue après l'événement.

Une méthode de clustering exclut la majorité des points comme bruit.

Un intervalle conforme perd sa couverture après un changement de population.

Identifier l'hypothèse rompue, proposer une vérification et une correction

Exemple ou activité originale du cours



Ressources : apprendre et pratiquer

R01 : livre gratuit ISLP, chapitres sur validation, ensembles et non supervisé.

R33 : MOOC Inria avec exercices, notebooks et vidéos.

R02–R26 : documentation officielle, exemples et fonctions utilisées.

Liens complets dans les notes et [resources/RESSOURCES.md](#)

Sources : R01, R33, R02 · liens et détails dans les notes



Ressources : articles et veille

R15 : SMOTE ; R27 : SHAP ; R29 : prédiction conforme.

R30 : model cards et documentation des limites.

R35–R37 : modèles tabulaires et lecture critique des benchmarks récents.



Sources : R15, R27, R29, R30, R35, R36, R37 · liens et détails dans les notes



Ce que vous savez maintenant défendre

Un protocole, des features et une métrique cohérents avec la décision.

Un modèle comparé, régularisé et optimisé sans utiliser le test pour choisir.

Une recommandation avec incertitude, explications et conditions de réévaluation.

Le livrable est une décision justifiée, accompagnée de preuves reproductibles

Exemple ou activité originale du cours



À VOUS DE JOUER

Chrys Fé-Marty NIONGOLO

[Ressources et notebooks sur GitHub](#)

